


CH1 - Clip 2.

오해하지 말라. ML은
성능만 좋다고 서비스할 수
없다.



CONTENT

01

연구하는 ML이
정말 활용될까?

02

실무 ML에서의
이해관계자와 목표

03

Computation
우선순위

04

Data 특성

05

공정성(Fairness)

06

해석가능성
(Interpretability)

07

Summary

오해하지 말라. ML은 성능만 좋다고 서비스할 수 없다.

1. 연구하는 ML이 정말 활용될까?

Research ML vs Production ML

Research ML vs Production ML

Research ML	비교 사항	Production ML
모델 성능 (SOTA : state-of-the-art)	ML 개발 목표	다양함 (관계자 별로 상이함)

Research ML vs Production ML

Research ML	비교 사항	Production ML
모델 성능 (SOTA : state-of-the-art)	ML 개발 목표	다양함 (관계자 별로 상이함)
빠른 학습	계산 우선순위	빠른 추론
높은 처리량	지연시간 vs 처리량	낮은 지연시간
이미 정해져 있음	데이터	계속해서 변함
연구되고 있으나 고려가 적음	공정성	매우 중요함
연구되고 있으나 고려가 적음	해석 가능성	매우 중요함

2. 실무 ML 에서의 이해관계자와 다양한 목표 설정


이해 관계자의 다양한 목표

목표 일치의 어려움

이해 관계자의 다양한 목표

이해관계자 다양성

- ML 프로젝트의 성공은 다양한 역할을 가진 이해관계자들의 협력에 의존.
- 이런 이해 관계자들은 본인의 역할에 따라 ML 에 대한 다양한 목표(Objective) 를 추구.



이해 관계자의 다양한 목표

Data Scientist & ML Engineer

- 모델 개발 및 훈련을 담당
- 주요 목표 : 모델 성능을 최대화하고 최신 기술과 알고리즘을 적용하여 최고 예측 결과를 달성

영업팀

- AI 제품의 광고 및 비즈니스 모델에 관여
- 주요 목표 : 소비자에게 어필할 수 있는 부분을 관심 갖고, 비즈니스 모델에서 돈을 벌 수 있도록 예측 결과를 내놓는 모델

제품 관리자

- 사용자 경험과 제품 기능을 관리
- 주요 목표 : 사용자 만족도를 높이며, 빠른 추론 및 훌륭한 사용자 경험을 제공하는 모델

이해 관계자의 다양한 목표

Infra Engineer & Backend Engineer

- 모델 운영과 인프라 관리 담당
- 주요 목표 : 모델을 안정적으로 운영하고 확장 가능한 시스템을 구축하여 성능을 유지

관리자

- 프로젝트 조율과 리소스 할당을 관리
- 주요 목표 : 조율을 통해 모든 이해관계자의 목표를 조화롭게 조율하고 프로젝트를 성공적으로 마무리. ML 인력이 없어도 되는 제품을 꿈꾸는...????

이해 관계자의 다양한 목표

만약 숙박 앱에서 추천 모델을 상품화하려고 한다면?

Data Scientist & ML Engineer

영업팀

제품 관리자

Infra Engineer & Backend Engineer

관리자

이해 관계자의 다양한 목표

만약 숙박 앱에서 추천 모델을 상품화하려고 한다면?

Data Scientist & ML Engineer

사용자가 숙박할 확률 높은 곳을 추천

영업팀

광고비를 많이 내는 숙박 업소를 추천하는 모델

제품 관리자

모델 추론 지연 속도를 200ms 이내로 할 수 있는 모델

Infra Engineer & Backend Engineer

모델 서빙 인프라의 안정성을 위해 모델 업데이트를 보류 희망

관리자

언젠가는 위 모든걸 다 AI가 해내면.. 그들을 내보낼 수 있겠지

이해 관계자의 다양한 목표

만약 숙박 앱에서 추천 모델을 상품화하려고 한다면?



모델 A

- Collaborative Filtering
- Accuracy 85%
- 사용자 선호도를 정밀하게 예측
- 새로운 레스토랑에 대한 추천 어려움
- 모델 개발 및 유지에 연간 8억 소요



모델 B

- Content-based Filtering
- Accuracy 75%
- 다양한 레스토랑과 새로운 레스토랑을 추천
- 사용자의 선호도를 정밀하게 예측이 부족
- 모델 개발 및 유지에 연간 5억 소요

목표 일치의 어려움

이해관계자 다양성으로 목표 일치의 어려움

- 모델 A와 모델 B가 있으나, 지연속도/모델 성능/해석 가능성의 차이가 있는 경우 어떤 모델을 선택하게 될까??
- 이해관계자들이 충돌하기 쉽고, 이로 인해 모델 상품화 방향성이 연구 모델과는 매우 다른 방향으로 흐른다



오해하지 말라. ML은 성능만 좋다고 서비스할 수 없다.

3. Computation 우선순위

Computation

Computation 중요 사례

Computation 우선순위

ML 최적화의 함정

- 모델의 성능 최적화를 위해 앙상블 모델을 구성하거나, 반복적인 모델 훈련을 하거나, 너무 복잡한 모델을 개발하게 된다.
- 이는 모델을 실제 상품에 활용할때, 추론 속도(input이 모델이 주어지고 output이 나오는 시간)가 느려져서 사용하기가 매우 어렵다.

대기시간 vs 처리량

- 이 두개는 항상 충돌한다. Research 분야에는 Throughput을 중시하고, Production 분야에서는 Latency를 중시한다.
- 대기시간 (Latency) : 사용자가 특정 작업을 요청한 후, 실제 결과를 반환받기까지 걸리는 시간.
 - 온라인 쇼핑 웹사이트에서 특정 제품을 검색하고 구매하기를 클릭한 후 해당 제품 페이지가 표시되기까지 걸리는 시간
- 처리량 (Throughput) : 특정 시간 동안 시스템이 처리하는 요청 또는 작업의 양.
 - 초당 처리되는 작업 수. 웹 서버가 초당 100개 요청 처리할 수 있으면 100req/second가 처리량.

Computation 중요 사례

Akamai 연구 내용

- 100ms의 지연이 사용자 전환율(Conversion rate) 7% 감소

Google

- 페이지 로드য়ে 3초 이상이 걸리면, 모바일 사용자 중 절반 이상이 페이지를 이탈

Computation 중요 사례

당신은 어떤가요?

당신이 주로 사용하는 앱의 지연 속도가 2배가 된다면...

오해하지 말라. ML은 성능만 좋다고 서비스할 수 없다.

4. Data 특성

Data 특성

Research ML vs Production ML

Research ML Data은 깔끔하다

- 연구 단계에서는 작업하는 데이터셋이 매우 깨끗하고 잘 정리되어 있어, 모델 개발과 훈련에 집중할 수 있음
- 연구 공동체에서 새로운 알고리즘과 기술을 벤치마킹하기 위해, 정적인 특성을 가지고 있음
- 다양한 많은 사람이 함께 객관적으로 논의를 할 수 있는 환경을 제공

Production ML Data는 지저분하다?

- 노이즈가 많고 구조가 복잡하며, 매 번 데이터가 지속적으로 변한다.
- 데이터는 매우 한 쪽으로 편향되어 있을수 있으며, 어떤 식으로 동작하는지도 알기 어렵다.
- 잘못된 데이터들이 상당히 많을 수 있으며, 정답 label이 존재하지 않을 수 있다.
- 사용자 데이터를 다루는 경우에는 개인 정보 보호와 규제 문제를 고려해야 한다.

오해하지 말라. ML은 성능만 좋다고 서비스할 수 없다.

5. ML Fairness

Fairness란 무엇인가?

Research ML vs Production ML

Fairness란 무엇인가?

Fairness?

- 한글로는 공정함.
- 모든 인간에 대해 동등하기 적용되는 것을 의미
- 인종,성별,연령,출신 국가 또는 기타 개인 특성과 관계 없이 모든 사용자나 그룹에게 동등한 서비스와 기회를 제공

AI Fairness

- AI의 공정함
- AI의 추론 결과가 모든 인간에 대해 동등하게 적용되어야함
- 하지만, ML 모델은 학습 데이터로부터 패턴을 학습하므로 불균형 데이터나 편견을 반영할 수 있음. 이로 인해 모델은 다른 그룹을 차별적으로 대할 수 있음

Fairness란 무엇인가?

공정하지 않은 AI

- 구인 기업의 인사 선발용 AI 모델이 남성보다 여성을 우대하여 불평등한 선택을 할 수 있음
- 금융 서비스에서 특정 인종, 성별 또는 사회 경제적 요소에 따라 특정 고객에게 대출을 거절하거나 높은 금리를 제공할 수 있음

AI Fairness 향상

- 다양한 훈련 데이터 수집
- 편견 감지 및 수정
- 투명성과 해석가능성 강화
- 사용자 참여(사용자 피드백으로 AI 수정)

Research ML vs Production ML

Research ML

- 고려되고 있으나 must have가 아님
- 연구 한계가 많음

Production ML

- AI Fairness가 **매우 중요함**. 어떻게 보면 일반적인 모델 성능보다 더 중요할 수 있음.
- **기업의 브랜드 이미지, 비즈니스 성패가 달려 있음**

6. Interpretability

Interpretability란 무엇인가?

AI 모델의 해석 방법

Research ML vs Production ML

Interpretability란 무엇인가?

Interpretability?

- AI의 결정 과정을 인간이 이해할 수 있도록 만드는 과정
- AI 모델이 왜 그런 결정을 내렸는지 설명할 수 있는 능력

Interpretability의 필요성

- 신뢰성 : 모델의 결정이 신뢰할 수 있어야 함
- 투명성 : 모델이 내린 결정을 설명 가능하게 만들어야 함
- 편향 식별 : 모델 내의 잠재적인 편향을 식별하고 수정해야 함
- 법적 및 윤리적 이슈 : 규정 및 윤리적 요구 사항을 준수하기 위해 모델 작동 방식을 이해해야 함

AI Interpretability 예시

- 의료 진단 : 암 진단, 질병 진단
- 금융 예측 : 특정 거래, 주식을 추천한 이유
- 자율 주행 자동차 : 사고 발생시, AI 모델이 주행 결정에 내린 근거

AI 모델의 해석 방법

전통적인 통계적 분석

- 모델 개발시 사용된 feature(데이터)와 결과 간의 상관관계를 분석

모델 해석 도구 사용

- 모델 내부의 결정 및 예측을 시각화하고 설명하는 데 도움주는 도구를 활용
- LIME : 모델에 대한 지역적 해석 가능성을 제공하는 기술
- SHAP : 게임이론의 shapley 값 개념을 기반으로 해석하는 기술
- LRP : 딥러닝 신경망의 예측 해석을 위한 방법 중 하나

Research ML vs Production ML

Research ML

- 고려되고 있으나 must have가 아님
- 연구 한계가 많음
- 학계에서는 모델 자체의 기본 성능(accuracy와 같은 metric)을 더 중시

Production ML

- AI Interpretability가 매우 중요함.
- 기업의 중요한 의사 결정에 활용될 경우, 그 근거가 확실해야함.
- 기업의 미래가 달려 있음

오해하지 말라. ML은 성능만 좋다고 서비스할 수 없다.

7. Summary

Research ML vs Production ML

Research ML vs Production ML

Research ML	비교 사항	Production ML
모델 성능 (SOTA : state-of-the-art)	ML 개발 목표	다양함 (관계자 별로 상이함)
빠른 학습	계산 우선순위	빠른 추론
높은 처리량	지연시간 vs 처리량	낮은 지연시간
이미 정해져 있음	데이터	계속해서 변함
연구되고 있으나 고려가 적음	공정성	매우 중요함
연구되고 있으나 고려가 적음	해석 가능성	매우 중요함

Research ML vs Production ML

만약 우리가 스마트기기 제조사를 운영한다면?



Research ML

- 기술 혁신에 초점
- 대용량 센서 데이터 수집/ 복잡한 딥러닝 알고리즘 개발
- 음성 인식, 자동화, 스마트 홈 제어 기능 향상



Production ML

- 스마트 기기 사용하는 고객에게 실시간 응답과 안정성에 주력
- 음성 명령 처리를 위한 모델 추론 속도를 최적화
- 서비스가 급격히 확장 가능 해야하므로, 모델은 분산환경에서 확장 가능하도록 설계
- 사용자 개인 정보와 보안에 대한 엄격한 요구사항 준수