

CH2 - Clip 2.

**학습 데이터 준비 1 (데이터
유형 & 저장소 & 품질)**

CONTENT

01

정형, 반정형, 비정형
데이터

02

실시간 데이터

03

데이터 저장과 관리

04

데이터 품질과 보안

1. 정형, 반정형, 비정형 데이터

데이터의 유형

정형 데이터

- 구조화된 데이터로 '표' 형태로 표현되며 고정된 스키마를 가짐
- 데이터 베이스, 스프레드시트 및 CSV 파일과 같은 데이터 소스에서 얻음
- 예시 : 고객 데이터 베이스 (고객 이름, 주소, 전화번호, 이메일과 같은 고정된 필드), 주문 데이터 베이스 (주문 번호, ID, 수량, 가격)

비정형 데이터

- 구조가 없거나 매우 제한적인 구조를 가지지 않는 데이터로 텍스트, 이미지, 오디오, 비디오 같은 형태를 가짐
- 예시 : 트위터의 트윗 (텍스트로 된 트윗, 특정 구조 따르지 않음), 의료 이미지 (X-ray 이미지 또는 MRI 스캔 이미지)

반정형 데이터

- 구조가 명확하게 정의되지 않은 데이터로 '일부' 구조화된 정보를 가짐
- XML, JSON, HTML과 같은 마크업 언어를 사용하여 주로 표현
- 예시 : 웹 스크래핑 데이터, 기업 문서 데이터 (회사 문서 중에서 특정 키워드나 구조화된 정보를 추출한 데이터)

데이터의 유형

정형 데이터 특징

- 고정된 스키마 : 정해진 필드 및 데이터 형식을 가짐
- SQL 쿼리 사용 가능 : 데이터 베이스 관리 시스템에 SQL 쿼리를 통해 데이터 검색 및 조작 가능
- 쉬운 분석 : 데이터 분석 도구와 머신러닝 모델에 쉽게 적용 가능

비정형 데이터 특징

- 구조가 없음 : 데이터는 자유 형식이며, 특정 구조를 따르지 않음
- 고도의 전처리 필요 : 데이터 전처리 및 특징 추출(feature extraction/engineering)이 고도의 기술로 필요하며, 자연어 처리/ 컴퓨터 비전 및 음성 처리 기술을 활용해야함

반정형 데이터 특징

- 일부 구조화된 정보 : 데이터 내에 구조가 정확히 정의되지 않았지만 일부 마크업 또는 태그를 가짐
- 데이터 파싱 필요 : 데이터 파싱을 통해 의미 있는 정보 추출이 필요
- 유연성 : 데이터 형식이 더 유연하며 새로운 정보를 추가하거나 수정하기 용이함

2. 실시간 데이터

스트리밍 데이터

IoT 데이터

실시간 데이터

실시간 데이터 개념

- 데이터를 실시간으로 분석하고 수행해야 하는 데이터
- 이미 저장된 것이 아닌, 실시간으로 데이터가 수집되는 것
- 예시 : 유튜브 시청 데이터, 금융 거래 데이터, IoT 센서 데이터

실시간 데이터 처리 필요성 예시

- 금융 거래 : 주식 거래 및 금융 거래 데이터는 실시간으로 처리되어야 하며 시장 조건에 따라 신속한 결정을 내려야 함
- IoT 센서 데이터(미세먼지) : 환경 데이터를 센싱하는 경우, 실시간으로 분석하여 환경 상태를 모니터링 하거나 경고를 생성

스트리밍 데이터

스트리밍 데이터 개념

- 지속적으로 생성되고 전송되는 데이터 스트림(물줄기)을 나타냄
- 시간이 지나면서 변경되며 새로운 데이터가 계속해서 이전 데이터에 추가됨 (지속적으로 전체 데이터 용량 증가)

스트리밍 데이터 처리 특징

- 무한한 데이터 스트림 : 데이터의 끝이 없고 지속적으로 생성되므로 스트리밍 데이터를 처리하기 위한 특수한 방법 필요
- 실시간 분석 : 데이터가 도착하자마자 분석되며, 지연이 발생하지 않아야 함

IoT 데이터

IoT 데이터 개념

- 다양한 종류의 데이터가 복합적으로 스트리밍 형식으로 수집
- 작은 Edge Device에서 수집되는 경우가 많음

IoT 데이터 처리 특징

- 대량 데이터 처리 : 일반적인 데이터들보다도 상대적으로 많은 데이터를 저장 및 처리할 수 있어야함
- 다양한 데이터 형식 : 다양한 형식과 프로토콜로 데이터가 전송되기 때문에, 데이터 변환 및 표준화가 필요할 수 있음
- 실시간 처리 & 모니터링 및 경고

3. 데이터 저장과 관리

데이터 저장소

데이터 버전 관리

데이터 저장소

데이터 저장소 종류

- Database (DBMS)
- NoSQL Database
- Data Warehouse
- Data Lake

데이터 저장소

DBMS

- 구조화된 데이터를 효율적으로 저장, 관리 및 검색하기 위한 소프트웨어 시스템
- SQL 을 사용하여 데이터 베이스에 대한 쿼리 및 조작을 지원
- MySQL, PostgreSQL ..

NoSQL DB

- 정형 데이터 외에도 반정형 및 비정형 데이터를 저장하고 관리하기 위한 데이터 베이스
- 데이터 형식 유연성 제공, 대량 데이터 처리와 분산 환경 확장 가능
- MongoDB, Cassandra, Redis ..

Data Lake


- 다양한 비구조화 데이터를 저장하는 시스템으로, 원시 데이터를 보관하고 나중에 분석 및 처리에 활용
- 스키마의 유연성을 제공하고 나중에 정의되거나 변경될 수 있으며, 쉽게 새로운 데이터 형식을 수용할 수 있음

Data Warehouse


- 다양한 데이터 원본에서 데이터를 추출, 변환 및 로드(ETL)하여 중앙 집계 및 분석을 위한 중앙 데이터 저장소를 만드는 시스템
- 주로 정형 데이터 중심. 구조화된 데이터를 저장하고 분석.

데이터 저장소


SQL



No SQL



데이터 저장소



데이터 버전 관리

데이터 버전 관리 중요성

- 데이터의 변경 이력을 추적하고 이전 상태로 롤백할 수 있게 하는 프로세스
- 데이터의 무결성과 안정성을 보장하며, 잘못된 변경으로 인한 문제를 예방

Git-LFS 혹은 Feature Store

- Git Large File Storage는 Git 확장 도구로 대용량 데이터 파일을 관리할 수 있음
- Feature Store는 Feature(Data 가공된 버전)의 버전 관리를 지원

4. 데이터 품질과 보안

데이터 품질

데이터 보안

데이터 품질 관리

데이터 품질의 중요성 및 영향

- 데이터 품질은 데이터가 정확하고 신뢰할 수 있는지는 나타냄
- 낮은 데이터 품질은 잘못된 분석 및 결정을 초래할 수 있으며, 비즈니스 프로세스에 영향을 미칠 수 있음 -> 의사 결정 오류

데이터 품질 검사 및 개선 방법

- 데이터 프로파일링, 데이터 클리닝, 중복 제거, 이상치 감지 및 데이터 표준화 같은 기술과 도구를 사용하여 품질 검사
- 데이터 입력 및 수집 프로세스를 개선하여 데이터 품질을 유지하고 향상

데이터 보안

데이터 보안이란

- 데이터를 무단 액세스, 변조, 유출 또는 파괴로부터 보호하는 것을 의미
- 데이터 위협은 해커, 악성 코드, 내부 유출, 사회 공학 및 자연 재해와 같은 다양한 형태로 나타날 수 있음
- 데이터 유출로 인한 법적 문제로 고려 필요

데이터 보안을 위한 방어적 조치

- 방어적 조치를 위해 암호화, 액세스 제어, 물리적 보안, 네트워크 보안, 모바일 기기 보안, 정책 및 교육 등이 포함
- 기업인 경우 데이터 보안 정책을 개발하고 직원 교육 및 보안 솔루션을 구현하여 데이터 보호를 강화해야 함

Summary

