

CH2 - Clip 3.

**학습 데이터 준비 2 (Data
Sampling)**

CONTENT

01

Data Sampling
이란?

02

Data Sampling
종류

03

Data Sampling
고려사항

1. Data Sampling 이란?

Data Sampling

Data Sampling은

- 큰 데이터 집합에서 작은 부분 집합을 추출하는 프로세스
- 통계 및 데이터 분석 분야에서 사용되는 일반적인 기술로, 데이터의 일부를 조사하고 전체 데이터 집합에 대한 결론을 도출하는 데 활용 -> 전체 데이터 셋에 대한 통찰력을 얻거나 계산/저장 공간을 줄이는데 도움

목적

자원 및 시간 절약: 전체 데이터 집합을 처리하거나 분석하는 데 걸리는 시간과 자원을 절약. 대규모 데이터 집합에서 무작위로 추출된 샘플은 대부분의 데이터를 다루지 않아도 결과를 얻을 수 있음

품질 향상: 데이터 샘플링은 데이터 품질을 향상시키는 데 도움. 이상치나 오류를 탐지하고 데이터 정제를 수행하기 위해 데이터의 작은 부분을 확인

통계적 추론: 데이터 샘플을 사용하면 통계적 추론을 수행. 추출된 샘플을 기반으로 모집단에 대한 통계적 추론을 수행하여 일반적인 패턴, 평균, 분포 등을 파악

데이터 시각화: 데이터 샘플을 사용하여 데이터 시각화를 수행하면 데이터를 더 잘 이해하고 시각적으로 표현할 수 있음. 이를 통해 패턴, 관계 및 트렌드를 시각적으로 파악 가능

데이터 테스트: 데이터 샘플링은 새로운 데이터 수집 및 분석 기술의 테스트와 실험에 유용. 더 많은 데이터를 수집하기 전에 시스템 및 알고리즘을 테스트 가능

2. Data Sampling 종류

Data Sampling 종류

Random Sampling

- 무작위로 데이터 집합에서 샘플을 선택하는 방법
- 각 데이터 포인트가 선택될 확률은 동일하며, 편향이 적게 대표성 있는 샘플을 얻을 수 있음

Stratified Sampling

- 데이터를 계층적으로 분류한 후, 각 계층에서 샘플을 추출하는 방법
- 각 계층의 특성을 고려하여 샘플을 얻기 위해 사용
- 예를 들어, 남성과 여성의 성별에 따라 샘플을 추출할 때 사용

Cluster Sampling

- 데이터를 여러 그룹 또는 cluster로 나누고, 몇 개의 cluster를 무작위로 선택한 후 선택된 cluster 내의 모든 데이터를 포함하는 방법.
- 데이터가 고루 분포되지 않은 경우에 유용
- 데이터가 클러스터로 그룹화 될 때 사용

Data Sampling 종류

Weight Sampling

- 데이터 포인트에 가중치를 할당하고 이러한 가중치를 기반으로 샘플을 추출하는 방법
- 데이터 포인트에 할당된 가중치는 해당 데이터 포인트의 중요성을 나타내며, 중요한 데이터는 더 자주 선택될 가능성이 높음
- 불균형 데이터 분포를 가진 경우 잘 활용됨 (이상치 탐지나 희귀 이벤트 분석과 같이 minor class data가 매우 적은 경우)

Importance Sampling

- 확률 분포에 기반한 통계 샘플링 기법.
- 베이지안 추론, 몬테 카를로 시뮬레이션, 결합 확률 분포의 추정 등

3. Data Sampling 고려 사항

Data Sampling 고려 사항

편향과 오차 관리

- 특정 데이터 세트에 대한 과소 또는 과대 표현이 일어나지 않도록 Sampling을 선정
- Sampling 과정 속에서 무작위성에 의한 변동이 많지 않도록 Sampling을 선정

Data Sampling 샘플 크기 및 신뢰 수준

- Data Sampling 에서 샘플 크기와 신뢰 수준은 중요한 결정 사항
- 통계적 방법을 사용하여 샘플 크기 및 신뢰 수준을 설정.
- 예를 들어, 모집단의 크기, 표본 분포의 변동성, 희귀 사건의 발생률 및 원하는 신뢰 수준 등을 고려해서 샘플 크기를 선정할 수 있음.