


CH2 - Clip 7.

Feature Engineering 1

(Data Cleansing)



CONTENT

01

**Data Cleansign
이란?**

02

**Data Cleansing
방법**

03

**Data Cleansing과
MLOps**

1. Data Cleansing 이란

Data Cleansing이란?

데이터 전처리 중 하나

- 데이터 전처리는 원시 데이터를 모델 학습에 적합한 형태로 가공하는 과정
- Data Cleansing은 노이즈 데이터, 이상치 데이터, 누락된 데이터를 처리해서 모델이 데이터 분포를 잘 학습할 수 있도록 전처리 과정

Data Cleansing 목적

- 데이터의 정확성과 품질을 확보하는 것
- 모델 학습에 영향을 끼치는 Noise Data, Anomaly Data, N/A Data를 식별하고 처리하여, 모델 성능을 향상

Data Cleansing 목적

Noise Data 식별

- Noise로 인해 모델 성능을 저하시키는 데이터를 식별하는 것을 목적
- Noise Data는 오류나 무작위한 값으로 인해 데이터 셋을 혼란스럽게 만들 수 있음

Anomaly Data 식별

- 다른 데이터와 너무나 다른 데이터(데이터 분포가 매우 한 쪽으로 편향된)이며, 모델 학습에 부정적 영향을 끼침

누락 Data 식별

- 다른 데이터에는 있지만 일부 데이터에 누락된 속성을 식별하여 보정

2. Data Cleansing 방법

Data Cleansing 방법

Noise Data 처리

- 데이터 분포를 시각화하고 통계적 방법 또는 기계 학습 방법을 사용하여 식별하고 처리
- 예를 들어, box plots 및 이상치 탐지 알고리즘을 활용할 수 있음

Anomaly Data 처리

- 이상치를 제거하거나 대체하는 두 가지 방법
- 각 기 장단점이 있으며, 제거하는 경우 잘못된 데이터 제거 문제가 있을 수 있으며 대체는 데이터 분포를 왜곡할 수 있다

누락 Data 처리

- 누락된 데이터를 제거하거나 대체하는 두 가지 방법
- 제거는 데이터 완전성을 유지하나, 데이터 수가 줄어들거나 class imbalance가 심해질 수 있음
- 대체는 평균, 중간값, 최빈값 등의 대체 방법을 사용할 수 있으며, 머신러닝 모델을 활용한 예측도 있음. 하지만, 잘못된 대체로 데이터 분포를 왜곡할 수 있음

3. Data Cleansing과 MLOps

MLOps에서 Data Cleansing

MLOps 자동화

- Data Cleansing을 자동화하고 관리함으로써 모델의 신뢰성을 높이며, 데이터 전처리 프로세스를 효율적으로 통합할 수 있음
- 데이터 전처리 파이프라인을 구축하고 모니터링하여 데이터 변화에 빠르게 대응하고, 모델 배포 및 관리에도 긍정적 영향을 제공