

CH2 - Clip 8.

Feature Engineering 2

(Feature Selection 통계 기법)

CONTENT

01

**Feature
Selection의 중요성**

02

통계 기법 소개

1. Feature Selection의 중요성

Feature Selection의 중요성

Feature Selection 이란?

- 입력 데이터의 특성 중에서 가장 관련성이 높거나 유용한 특성을 선택하고, 불필요한 특성을 제거하는 과정
- 머신 러닝 모델을 개선하고, 모델 효율성을 향상시킬 수 있음

Feature Selection 중요성

- **차원의 저주** : 높은 차원의 데이터는 모델 학습에 시간이 오래 걸릴 뿐만 아니라, 과적합의 위험이 있음
- **계산 효율성** : 중요하지 않은 특성을 제거하면 계산 효율성이 향상됨
- **모델의 해석** : 중요한 특성만 사용하면 모델의 해석이 더 쉬워짐

2. 통계 기법 소개

통계 기법

통계 기법 종류

- ANOVA (일원분산분석)
- Chi-squared Test (카이 제곱 검정)

ANOVA (일원 분산 분석)

ANOVA란?

- 카테고리별 numeric data 분포 차이를 검증하는 방법
- 예를 들어, 성별에 따른 키 분포 분석 검증이 가능
- 전제 : 정규성, 등분산성, 독립성 -> 만족하지 않으면 해당 검정을 신뢰할 수 없음 (정규성, 등분산성 만족하지 않는 경우가 많기 때문에, 비모수 검정인 크루스칼 월리스 검정을 활용하기도 함)

ANOVA 원리

- 두 개 이상의 그룹 간의 평균 차이가 통계적으로 의미 있는지 평가하는 방법
- 계산식
$$F = \text{Between group variance} / \text{Within group variance}$$
- 해석
 - F 값이 크면 그룹 간의 평균 차이가 통계적으로 유의미하다고 볼 수 있음
 - p-value를 통해 통계적 유의미성을 확인할 수 있음 (0.05이하인 경우를 유의미성 있다고 가정)

Chi-Squared Test

카이제곱 검정이란?

- 두 범주형 변수에 대한 분석 방법
- 예를 들어, 성별에 따른 선호 영화 장르 비교 문제
- 카이 제곱 검정은 3가지 종류가 있으며, 데이터 수집 방법과 가설에 따라 나뉨.

카이제곱 검정 3가지 유형

- 적합도 검정
변수 1개인 경우
기존에 알려진 기준이 존재하는 검정
예시) 상자 안에 공 3개가 같은 비율로 알려져 있음. 공 100개를 뽑았을 때, 각 색의 비율이 구해짐 -> 기존에 알려진 공 비율 분포를 따르는지 검정
- 독립성 검정
변수 2개인 경우
범주형 두 변수가 서로 연관되어 있는지 여부를 결정
예시) 성별과 흡연 여부 관계를 알고 싶어서 200명을 추출하여 조사한 경우\
- 동질성 검정
변수 2개인 경우
범주형 두 변수의 관계를 알기 위한 검정은 아님. 각 그룹들이 동질한 지 알고 싶은 검정
예시) 남자와 여자 흡연율 차이가 있는지 흡연율을 조사한 후, 두 그룹의 흡연율이 같은지 여부를 검정

Summary

Summary

- Feature Selection은 모델의 성능, 해석력, 계산 효율성을 향상시키는 중요한 과정
- 위의 두 통계 기법이 이것에 활용될 수 있음