

CH2 - Clip 11.

Feature Engineering 5

(Feature Reduction)



01

**Feature
Reduction이란?**

02

PCA

03

LDA

04

T-SNE

05

Auto Encoder

1. Feature Reduction이란?

Feature Reduction이란?

Feature Reduction?

- 데이터의 차원(feature 수)를 줄이는 과정을 의미
- 데이터셋에는 수십,수백 또는 그 이상의 특성이 포함될 수 있는데, 모든 특성이 유용하거나 필요한 것은 아님
- 불필요한 특성을 제거하거나, 여러 특성을 결합하여 새로운 특성을 생성하는 식으로 수행

Feature Selection VS Feature Reduction

Feature Selection	비교 사항	Feature Reduction
특성 중에서 가장 중요한 것만 선택하는 과정. 선택되지 않은 특성들은 완전히 제거	정의	특성 일부를 제거하거나, 여러 특성을 결합하여 새로운 특성을 생성하는 과정
1) 원본 데이터 특성 유지 2) 해석이 쉬워질 수 있음	특징	1) 원본 데이터 특성이 직접적으로 쓰이지 않음 2) 해석이 어려울 수 있음

Feature Reduction 이란

방법론

- PCA
- LDA
- T-SNE
- AutoEncoder
- ...


2. PCA

Principal Component Analysis (PCA)

정의

- 선형 차원 축소 방법
- 데이터의 분산이 최대가 되는 방향으로 데이터를 투영(Projection)하여, 원본 데이터의 차원을 축소하는 기법
- 원본 데이터의 정보 손실을 최소화하면서 차원을 축소
- 수식

데이터 X의 공분산 행렬을 계산
 공분산 행렬의 고유값과 고유벡터를 계산
 고유값이 큰 순서로 K개의 고유 벡터를 선택
 선택된 고유벡터로 데이터를 투영하여 차원을 축소



출처 : 위키피디아


3. LDA

Linear Discriminant Analysis (LDA)

정의

- 분류 문제에 적합
- 클래스 간 분산은 최대로, 클래스 내 분산은 최소로 만드는 방향으로 데이터를 투영하는 기법
- 각 클래스를 잘 구분할 수 있는 특성을 생성하는 것이 목표
- 수식

클래스 내 분산 행렬과 클래스간 분산 행렬을 계산
두 행렬의 고유값과 고유벡터를 계산
고유값이 큰 순서로 K개의 고유벡터를 선택
선택된 고유벡터로 데이터를 투영하여 차원을 축소




출처 : 위키피디아

4. t-SNE

t-Distributed Stochastic Neighbor Embedding (t-SNE)

정의

- 고차원 데이터의 구조를 저차원에서 유지하려는 비선형 차원 축소 기법
- 원본 고차원 공간에서의 데이터 포인트 간의 유사도와 저차원 공간에서의 데이터 포인트 간의 유사도를 비슷하게 만들려고함
- 수식
 - 고차원에서 두 데이터 포인트와 유사도를 가우스 분포를 이용해 계산
 - 저차원에서 두 데이터 포인트간의 유사도를 t-분포를 이용해 계산
 - 1)과 2)에서 구한 계산식의 차이가 최소가 되도록 데이터 포인트를 조정




출처 : scikit-learn.org

5. AutoEncoder

AutoEncoder

정의

- 딥러닝 기반의 비지도 학습 모델
- 입력 데이터를 압축된 표현으로 인코딩한 후 다시 디코딩하여 원래 입력 데이터를 재구성
- 중간에 압축된 표현은 원본 데이터의 차원보다 훨씬 작을 수 있으며, 이 표현을 사용하여 특성을 축소 할 수 있음
- 장점 : 앞의 방법과 달리 비선형 관계를 포착할 수 있으며, 대용량 데이터에서 효과적



출처 : <https://kr.mathworks.com/discovery/autoencoder.html>