

CH2 - Clip 13.

Feature Engineering 7

(Data Scaling & Encoding)

01

Data Scaling과 Data Encoding

02

Data Scaling 방법론

03

Data Encoding 방법론

1. Data Scaling과 Data Encoding

Data Scaling과 Data Encoding

정의

- **Data Scaling** : 다양한 Feature의 값 범위를 표준화하거나 정규화하는 과정. 알고리즘의 성능과 학습 속도에 큰 영향을 미칠 수 있음
- **Data Encoding** : Category형 변수를 숫자형 변수로 변환하는 과정. 대부분의 머신러닝 알고리즘(컴퓨터 머신 등)은 숫자형 데이터만 처리할 수 있으므로 Encoding은 필수적인 전처리 단계.

필요성

- **성능 최적화** : 올바른 scaling과 encoding은 모델의 성능을 향상시킬 수 있음. 잘못된 scale 또는 encoding은 알고리즘이 학습을 제대로 하지 못하게 만들 수 있음
- **학습 속도 향상** : Scaling된 데이터는 경사 하강법과 같은 최적화 알고리즘의 수렴을 빠르게 만듦
- **데이터 이해력 강화** : 적절한 encoding을 통해 데이터 구조와 관계를 더 잘 이해할 수 있음

Data Scaling과 Data Encoding

방법론

- **Data Scaling**

- Min-Max Scaling
 - Standard Scaling (Z-Score Normalization)
 - Robust Scaling

- **Data Encoding**

- Label Encoding
 - One-Hot Encoding
 - Ordinal Encoding

2. Data Scaling 방법론

Data Scaling 방법론

Min-Max Scaling

- 데이터를 0과 1사이의 값으로 변환하여 모든 feature의 scale을 동일하게 변환
- 단점 : 이상치에 민감할 수 있음
- 수식 :

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

예시

- Original Data : [2, 4, 6, 8, 10]
- Min-Max Scaled Data (0 to 1)
 - $X_{norm} = (2-2)/(10-2) = 0$
 - $X_{norm} = (4-2)/(10-2) = 0.25$
 - ...
 - Result = [0, 0.25, 0.5, 0.75, 1]

Data Scaling 방법론


Standard Scaling

- 데이터의 평균을 0, 표준편차를 1로 변환
- 장점 : 데이터 분포를 정규 분포와 유사하게 만들. 많은 머신러닝 알고리즘이 이런 분포를 가정하기 때문에 유용
- 단점 : 모든 feature의 범위가 동일하지는 않을 수 있음
- 수식 :

$$X_{standard} = \frac{X - \mu}{\sigma}$$

예시

- Original Data : [2, 4, 6, 8, 10]
- 평균 : 6, 표준편차 : 2.83
 - $X_{standard} = (2-6)/2.83 = -1.41$
 - $X_{standard} = (4-6)/2.83 = -0.71$
 - ...
 - Result = [-1.41, -0.71, 0, 0.71, 1.41]



출처 : scikit-learn.org

Data Scaling 방법론


Robust Scaling

- 중앙값과 IQR(Interquartile Range)을 사용하여 이상치의 영향을 최소화
- 장점 : 이상치의 영향을 크게 받지 않음
- 단점 : 데이터 분포를 왜곡할 수 있음
- 수식 :

$$X_{robust} = \frac{X - Q1}{Q3 - Q1}$$

예시

- Original Data : [2, 4, 6, 8, 100] (100은 이상치로 간주)
- Q1 : 3, Q3 : 8, IQR : 5
 - $X_{robust} = (2-3)/5 = -0.2$
 - $X_{robust} = (4-3)/5 = 0.2$
 - ...
 - Result = [-0.2, 0.2, 0.6, 1, 1.94]



출처 : scikit-learn.org

3. Data Encoding 방법론

Data Encoding 방법론

Label Encoding

- 카테고리 값을 순차적인 정수로 변환
- 장점 : 간단하게 카테고리형 변수를 숫자로 변환할 수 있음
- 단점 : 알고리즘이 숫자 간의 관계를 잘못 해석할 수 있음

예시

- Original Data : [Red, Blue, Green]
- Label Encoded Data : Red -> 0, Blue -> 1, Green -> 2
- Results : [0,1,2]

Data Encoding 방법론

One-Hot Encoding

- 각 카테고리 값에 대해 새로운 binary feature를 생성
- 장점 : 숫자 간의 관계를 고려하지 않아도 됨
- 단점 : feature 수가 크게 증가할 수 있음

예시

- Original Data : [Red, Blue, Green]
- One-Hot Encoded Data
 - Red -> [1, 0, 0]
 - Blue -> [0, 1, 0]
 - Green -> [0, 0, 1]

Data Encoding 방법론

Ordinal Encoding

- 순서가 있는 카테고리 값을 순차적인 정수로 변환
- 장점 : 순서 정보를 유지하면서 카테고리형 변수를 숫자로 변환할 수 있음
- 단점 : 순서가 없는 변수에 사용하면 오류를 유발할 수 있음

예시

- Original Data : [Low, Medium, High]
- Ordinal Encoded Data
 - Low -> 1
 - Medium -> 2
 - High -> 3
 - Result : [1,2,3]

Summary

Summary

- Data Scaling과 Encoding이 모델 성능에 영향