

CH2 - Clip 14.

Model Training



01

**Model
Training 이해**

02

**문제 유형에 따른
Model Training**

03

**Labeling과
Training 분류**

04

Training 유형

1. Model Training 이해

Model Training

정의

- 머신 러닝에서 핵심 과정 중 하나로, 데이터를 사용하여 머신러닝 알고리즘을 훈련시켜 예측이나 분류 등의 작업을 수행하는 모델을 생성하는 과정
- 목적 : 주어진 데이터를 기반으로 알고리즘이 일반적인 패턴을 학습하고, 이를 바탕으로 미지의 데이터에 대해 예측하거나 분류하는 능력을 개발하는 것

- 구성 요소

데이터 : 훈련 데이터셋은 모델을 훈련시키기 위해 사용되는 데이터

알고리즘 : 다양한 머신러닝 알고리즘이 있으며, 각 각의 알고리즘은 특정 문제나 데이터 유형에 가장 잘 맞을 수 있음

손실함수 : 모델의 예측과 실제 값 사이의 차이를 측정하는 함수

최적화기 : 손실 함수의 값을 최소화하는 방향으로 모델의 파라미터를 업데이트하는 알고리즘

Model Training

과정

- 데이터 준비
데이터 수집, 정제, 전처리를 통해 훈련 데이터셋을 준비
훈련 데이터는 보통 features와 label로 구성
- 모델 선택
문제의 유형(회귀, 분류, 클러스터링, 생성형 등)에 따라 적합한 머신러닝 알고리즘 선택
주어진 상황(데이터, 리소스)에 따라 적합한 모델 학습 유형(online training, transfer learning, active learning ..)을 선택
- 모델 초기화
무작위의 초기 파라미터 값으로 모델 초기화
- 훈련
데이터를 모델에 전달하여 예측을 생성
손실 함수를 사용해 예측과 실제 레이블 간의 오차를 계산
최적화를 사용하여 손실을 최소화하는 방향으로 모델 파라미터를 업데이트
위의 과정을 반복하며 모델 훈련
- 평가
별도의 validation dataset을 사용하여 모델 성능 평가
필요한 경우, 모델 구조나 파라미터를 조정하고 다시 훈련 진행
- 튜닝
하이퍼 파라미터 튜닝, feature engineering, 알고리즘 선택 으로 모델 성능 최적화

2. 문제 유형에 따른 Model Training

문제 유형에 따른 Model Training

유형

- 회귀 (Regression)
- 분류 (Classification)
- 클러스터링 (Clustering)
- 생성형 (Generative)

회귀 (Regression)

목적

- 연속적인 값을 예측하는 것
- 독립 변수와 종속 변수 간의 선형 관계를 모델링

관련 알고리즘

- Linear Regression : 가장 기본적이고 널리 사용되는 알고리즘 중 하나
- Decision Tree Regression : 비선형 관계를 갖는 데이터에도 적용 가능
- Random Forest Regression : 여러 Decision Tree를 결합한 알고리즘, 높은 정확도
- Support Vector Regression : 고차원 데이터에 적합하며, 복잡한 비선형 관계도 학습 가능

예시

- 부동산 가격 예측, 연봉 예측

분류 (Classification)

목적

- 주어진 입력에 대해 두 개 이상의 클래스 중 하나를 예측하는 것
- Logistic 함수를 사용하여 이진 또는 다중 클래스 분류 문제를 해결

관련 알고리즘

- Logistic Classification
- Decision Tree Classification
- Random Forest Classification : Decision Tree의 과적합 문제를 줄이기 위한 알고리즘
- K-Nearest Neighbors : 주어진 데이터 포인트와 가장 가까운 K개의 이웃을 바탕으로 1분류
- Neural Networks : Neural network 구조를 적용

예시

- 스팸 메일 분류, 병 진단

클러스터링 (Clustering)

목적

- 비슷한 특성을 갖는 데이터를 그룹으로 묶는 것
- 데이터를 K개의 Cluster로 분할하여 활용

관련 알고리즘

- K-Means : 데이터를 K개의 Cluster로 분류, 각 Cluster 중심을 최적화
- DBSCAN : 밀도 기반의 Clustering, Noise가 있는 데이터에 적합
- Hierarchical Clustering : Tree 구조의 Cluster를 생성하며, 다양한 수준의 클러스터링을 제공

예시

- 고객 세그멘테이션, 문서 군집화

생성형 (Generative)

목적

- 새로운 데이터를 생성하거나, 데이터의 분포를 학습하는 것
- 데이터의 분포를 학습하고, 분포에 따라서 적절한 데이터를 생성하는 모델

관련 알고리즘

- Restricted Boltzmann Machine : 이진 값의 입력과 출력 사이의 확률적 관계를 학습
- Variational Autoencoder : 데이터의 Latent Space를 학습하며, 새로운 데이터를 생성
- Generative Adversarial Network : 생성자와 판별자 두 네트워크가 경쟁하면서 데이터의 분포를 학습

예시

- 추천 시스템, 이미지 생성, ChatGPT

3. Labeling과 Training 분류

Labeling과 Training 분류

Supervised Learning

- Data에 모든 Labeling이 존재한 상태에서의 Learning 방식




Semi-Supervised Learning

- 일부 Data만 Labeling이 존재하며, 나머지는 Labeling이 존재하지 않는 상황에서의 Learning 방식

Self-Supervised Learning

- Data에 모든 Labeling이 존재하지 않으며, 모델이 스스로 학습할 수 있도록 설계된 Learning 방식

Labeling과 Training 분류



4. Training 유형

Training 유형

유형

- Batch Training
- Online Training
- Transfer Learning
- Reinforcement Learning
- Active Learning
- Ensemble Learning

Batch Training

정의

- 전체 훈련 데이터를 한 번에 사용하여 모델을 학습시키는 방법

설명

- 모든 훈련 데이터를 한 번에 사용하여 그래디언트를 계산하고 가중치를 업데이트
- 손실 함수의 그래디언트는 다음과 같이 계산

L 은 하나의 훈련 샘플에 대한 손실 함수이고, h 는 가설 함수, m 은 훈련 샘플의 수

$$\nabla_{\theta} J(\theta) = \frac{1}{m} \sum_{i=1}^m \nabla_{\theta} L(y^{(i)}, h_{\theta}(x^{(i)}))$$

사용 예시

- 데이터 셋 크기가 작을 때, 또는 충분한 계산 지원이 있을 때 적합

Online Training

정의

- 데이터를 작은 묶음(배치)으로 나누어 순차적으로 모델을 학습시키는 방법

설명

- 데이터를 mini-batch라는 작은 단위로 나누어 학습을 진행하며, 각 mini-batch마다 가중치를 업데이트
- 실시간으로 데이터가 수신되는 시스템에서 효과적
- 더 빠른 수렴을 위해 mini-batch 크기나 learning-rate 을 조정할 필요가 있을 수 있음

$$\theta \leftarrow \theta - \eta \nabla_{\theta} L(y^{(i)}, h_{\theta}(x^{(i)}))$$

사용 예시

- 실시간 트래픽 예측, 주식 가격 예측 등 실시간으로 데이터가 업데이트되는 시스템에서 사용

Transfer Learning

정의


- 사전 훈련된 모델을 사용하여 새로운 문제에 대한 학습을 가속화하는 방법

설명

- 이미 훈련된 모델의 일부 layers(예: CNN의 처음 몇 layer)를 재사용하여 새로운 문제에 적용
- 재사용된 layer의 가중치는 고정될 수도 있고, 추가적인 학습을 통해 조정될 수도 있음

사용 예시

- ImageNet에서 사전 훈련된 모델을 사용하여 특정 이미지 분류 문제(고양이와 개 분류 등)에 적용



Reinforcement Learning

정의


- 에이전트가 환경과 상호작용하면서 보상을 최대화하는 행동을 학습하는 방법

설명

- 에이전트는 상태 E에서 행동 A를 선택하고, 그에 따른 보상 R을 받음
- 이후 상태와 행동을 업데이트
- 대표적인 알고리즘으로는 Q-learning, DQN, Policy Gradient 등이 있음

사용 예시

- AlphaGo, 자율 주행, 게임 플레이 최적화



출처 : matworks.com

Active Learning

정의

- 모델이 스스로 학습에 사용할 데이터를 선택하는 방법

설명

- 일반적으로 Labeling이 비용이 많이 드는 경우에 효과적 (스스로 필요한 샘플을 선택하고, 전문가에게 Labeling을 요청하는 식으로 시스템 구성)
- 일반적으로 불확실성이 높은 Sample을 선호

사용 예시

- 의료 영상 분석에서 모델이 확신하지 못하는 영상을 의사에게 Labeling 요청을 할 때 사용

Ensemble Learning

정의


- 여러 개의 모델을 조합하여 하나의 강력한 모델을 만드는 방법

설명

- 여러 개의 모델을 훈련하고 그 결과를 조합
- 대표적인 방법으로 Bagging, Boosting이 있음

사용 예시

- Kaggle에서 많이 활용됨



Summary

Summary

- 다양한 모델 Training 유형이 있고, 이것들을 쉽게 반복 수행하고 적용이 가능