

CH2 - Clip 14.

Model Evaluation



01

Model Evaluation

02

Evaluation 방법

03

Evaluation Metrics

1. Model Evaluation

Model Evaluation

정의

- 머신러닝 또는 딥러닝 모델의 성능을 평가하고 검증하는 과정
- 모델이 학습 데이터에 대해서만 잘 작동하는지, 아니면 새로운(이전에 본 적 없는) 데이터에 대해서도 잘 동작하는지(일반화가 잘 되었는지)를 평가
- 이를 위해 다양한 Evaluation Metrics을 사용하여 모델의 예측 성능을 평가

필요성

- Overfitting의 방지 : 새로운 데이터에 대한 성능이 떨어지는 현상(학습 데이터에 과도하게 최적화)
- 모델 선택 : 여러 알고리즘 또는 하이퍼 파라미터로 다양한 모델을 학습할 경우, 어떤 모델이 가장 좋은 성능을 나타내는지 판단하기 위해 필요
- 성능 향상의 지표 : 모델 성능을 측정해서 어떤 부분에 개선이 필요한 지, 어떤 전략이 성능 향상에 효과적인지 알 수 있음
- 비즈니스 목표 달성 : 비즈니스 목표를 달성하기 위해 모델 성능이 어느 정도까지 개선되어야 하는지 알 수 있음
- 신뢰성 및 투명성 : 모델 성능을 공정하게 평가하고, 그 결과를 공유해서 모델에 대한 신뢰성을 높이고 의사 결정 과정의 투명성을 확보 가능

Model Evaluation

방법

- Holdout
- Cross Validation
 - K-Fold Cross validation
 - Stratified K-Fold Cross validation
 - Leave-One-Out
 - Leave-P-Out

Metrics

- Accuracy
- Precision
- Recall (Sensitivity)
- F1-Score
- MSE
- MAE
- R-squared

2. Evaluation 방법

Holdout

정의

- 데이터를 Training set와 Test set로 한 번만 분할
- 일반적으로 데이터의 70~80%는 훈련에 사용하고, 나머지 20~30%는 테스트에 사용

특징

- 장점 : 간단하고 빠르게 실행
- 단점
 - 데이터 셋의 크기가 작은 경우, Test set의 결과가 불안정 할 수 있음
 - 데이터 분할의 random한 특성으로 결과가 크게 달라질 수 있음

Cross Validation

정의

- 데이터를 여러 부분으로 나누어, 한 부분을 Test Set로 사용하고 나머지 부분으로 모델을 학습시킨다. 이 과정을 각 부분마다 반복한다.

다양한 방법

- K-Fold
- Stratified K-Fold
- Leave-One-Out (LOO)
- Leave-P-Out (LPO)


Cross Validation : K-Fold

정의

- 데이터를 K개의 부분(또는 'Fold')로 나눈 후, 각 Fold를 한 번 씩 Test Set로 사용하고 나머지 K-1개 Fold를 훈련 세트로 사용.
- 이 과정을 K번 반복

특징

- 장점 : 모든 데이터 포인트가 훈련과 테스트에 모두 사용되므로 결과가 더 안정적
- 단점 : 모델을 K번 학습해야 하므로 계산 비용이 높음



출처 : scikit-learn.org

Cross Validation : Stratified K-Fold

정의

- K-Fold CV의 변형으로, 각 Fold에서 클래스 비율이 전체 데이터셋의 클래스 비율과 동일하게 유지하도록 유지

특징

- 장점 : Class Imbalance가 있는 데이터 셋에 효과적
- 단점 : K-Fold CV와 마찬가지로 계산 비용 높음

Cross Validation : Leave-One-Out(LOO)

정의

- K-Fold의 매우 특수한 경우
- N개의 데이터 포인트가 있을 때, 하나의 데이터 포인트를 Test로 사용하고 나머지 N-1개를 훈련에 사용
- 이 과정을 N번 반복

특징

- 장점 : 작은 데이터셋에 효과적
- 단점 : 매우 높은 계산 비용이 발생. 각 데이터 포인트에 대해 모델을 재학습

Data 1 (Not Fold)					
	Data 2 (Not Fold)				
		Data 3 (Not Fold)			
			Data 4 (Not Fold)		
				Data 5 (Not Fold)	
					Data 6 (Not Fold)

Cross Validation : Leave-P-Out(LPO)

정의

- N개의 데이터 포인트 중 P개를 테스트로 사용하고 나머지를 훈련에 사용 (P=1이면 LOO와 동일)
- 가능한 모든 조합에 대해 반복

특징

- 장점 : LOO의 변형으로, P개의 데이터 포인트에 대한 영향을 조사 가능
- 단점 : 계산 비용이 아주 높음

Data Seg 1 (Not Fold)					
	Data Seg 2 (Not Fold)				
		Data Seg 3 (Not Fold)			
			Data Seg 4 (Not Fold)		
				Data Seg 5 (Not Fold)	
					...

3. Evaluation Metrics

Evaluation Metrics

유형

- Accuracy
- Precision
- Recall
- F1-Score
- MSE
- MAE
- R-squared

Confusion Matrix

정의

- 실제 클래스와 모델이 예측한 클래스 간의 관계를 2x2 테이블로 나타낸 것
- 분류 문제에서 주로 사용된다

구성 요소

- True Positive
- False Positive
- True Negative
- False Negative

		Predicted	
		Negative -	Positive +
Actual	Negative -	True Negative (TN)	False Positive (FP)
	Positive +	False Negative (FN)	True Positive (TP)

Accuracy

정의

- 전체 예측 중 올바르게 예측된 것의 비율

설명

- $\text{Accuracy} = (\text{True Positives} + \text{True Negatives}) / \text{Total Predictions}$
- 균등하게 분포된 클래스에서 사용

예시

- 고양이와 개를 구분하는 모델에서 100개의 이미지 중 95개를 올바르게 분류했을 경우, $\text{Accuracy} = 95\%$

Precision

정의

- 양성으로 예측된 것 중 실제로 양성인 것의 비율

설명

- $\text{Precision} = (\text{True Positives}) / (\text{True Positives} + \text{False Positive})$
- False Positive를 줄이는 것이 중요할 때 사용

예시

- 스팸 메일 분류에서 100통 중 10통을 스팸으로 예측했으나, 그 중 9통만 실제로 스팸이라면 Precision은 90%

Recall

정의

- Sensitive라고도 불림
- 실제 양성 중 양성으로 예측된 것의 비율

설명

- $\text{Recall} = (\text{True Positives}) / (\text{True Positives} + \text{False Negatives})$
- 모든 양성 케이스를 식별해야 할 때 중요.

예시

- 100명 중 10명이 질병이 있고 ,모델이 7명만을 정확하게 진단했을 경우, 재현율은 70%. (코로나인 경우 중요)

F1-Score

정의

- Precision과 Recall의 조화 평균

설명

- $F1\text{-Score} = 2 * (Precision * Recall) / (Precision + Recall)$
- Precision과 Recall 사이의 균형을 찾아야 할 때 사용

예시

- Precision 80%, Recall 90%이면 F1-Score는 85%

ROC-Curve and AUC

ROC Curve

- 다양한 Threshold에서 모델의 Recall 대비 거짓 양성 비율을 나타내는 그래프
- 모델의 성능을 시각적으로 평가하며, Threshold 선택의 중요성을 강조

AUC

- AUC는 ROC 곡선 아래 영역을 나타내며, 모델의 전반적인 성능을 단일 숫자로 나타냄
- 모델 성능을 요약할 때 유용하며, 0.5(무작위 예측) ~ 1(완벽한 예측) 사이의 값을 가짐

MSE (Mean Squared Error)

정의

- 평균 제곱 오차
- 실제 값과 예측 값의 차이를 제곱하여 평균한 값

설명

- 일반적인 회귀 문제에서 널리 사용

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

예시

- 집 가격 예측에서 실제 가격이 200,000달러이고 예측값이 220,000달러 인경우, 오차는 20,000.

MAE (Mean Absolute Error)

정의

- 실제 값과 예측 값의 차이를 절대값으로 평균한 값

설명

- 큰 오차에 덜 민감한 평가 지표가 필요할 때 사용

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

예시

- 날씨 예측에서 실제 온도와 예측 온도의 차이를 구할 때 사용

R-Squared

정의

- 모델이 데이터의 분산을 얼마나 잘 설명하는지 나타내는 지표

설명

- 모델의 설명력을 평가할 때 사용

$$R^2 = 1 - \frac{\text{MSE of the model}}{\text{MSE of the baseline}}$$

예시

- 주식 가격 예측 모델의 성능을 평가할 때, R-Squared 값을 사용하여 모델이 주식 가격의 변동을 얼마나 잘 설명하는지 판단

Summary

Summary

- 머신 러닝 모델의 성능을 평가를 통해서 성능을 보장 -> MLOps를 통한 효율화