

CH2 - Clip 18.

Model Selection



01

**Model
Selection이란?**

02

**Model
Selection 방법**

03

**MLOps에서의
Model Selection**

1. Model Selection이란?

Model Selection

정의

- 주어진 데이터에 대해 가장 잘 맞는 머신러닝 알고리즘을 선택하는 과정
- 데이터의 특성을 잘 표현할 수 있는 모델의 구조를 결정하고, 최적의 hyperparameter를 찾는 것이 포함
- 과정의 목표는 일반화 오류(Generalization error)를 최소화하는 것, 새로운 데이터(unseen data)에 대한 모델의 예측 성능을 높이는 것

2. Model Selection 방법

Model Selection

방법론

- Train/Validation/Test Split Validation
- Cross-Validation
- Information Criterion Approaches
- Grid Search, Random Search, Bayesian Optimization
- Ensemble Methods

Model Selection

Tranin/Validation/Test Split

- 데이터를 훈련, 검증 그리고 테스트 세트로 나눔
- 훈련 데이터로 다양한 모델을 학습시키고, 검증 데이터를 사용하여 성능을 평가하여 최적의 모델을 선택
- 선택된 모델은 테스트 데이터로 한 번 더 평가하여 최종 성능을 검증

Model Selection

Cross-Validation

- 데이터 세트를 k 개의 서브셋으로 나누고, $k-1$ 개의 서브셋으로 모델을 훈련시킨 후 나머지 1개의 서브셋으로 성능을 검증
- 이 과정을 k 번 반복하여 모든 서브셋이 최소 한 번은 검증 데이터로 쓰임
- 각 반복에서의 성능을 평균내어 모델 성능을 평가하고 선택

Model Selection

Information Criterion Approaches

- AIC 또는 BIC 같은 정보 기준을 사용하여 모델의 복잡성과 성능 사이의 균형을 찾음
- 위 기준은 모델의 좋은 성능을 보상하고, 과도하게 복잡한 모델에 대해서는 패널티를 부여

AIC

- 모델의 복잡성(모델의 파라미터 수)과 모델의 적합도(모델이 데이터를 얼마나 잘 설명하는지)를 함께 고려
- Maximum likelihood에 대해 적합도를 제공하고, 모델의 복잡성에 비례하는 패널티를 부여
- 모델을 비교해서 AIC가 가장 낮은 모델을 일반적으로 선택

BIC

- AIC와 유사하나, 샘플 크기에 대한 패널티를 추가하여 더 큰 샘플 크기에 대해서는 더 큰 패널티를 부과.
- 즉, AIC에 비해 더 간단한 모델을 선호
- 모델을 비교해서 BIC가 가장 낮은 모델 선택

Model Selection

Grid/Random/Bayesian Search Optimization

- Grid Search : 모든 hyperparameter 조합을 시험하여 최적의 조합 찾기
- Random Search : hyperparameter의 특정 범위 내에서의 무작위로 조합을 선택하여 시험
- Bayesian Optimization : hyperparameter 성능을 모델링하고, 이 모델을 사용하여 시험해 볼 가장 유망한 hyper-parameter를 선택

Model Selection

Ensemble Methods

- 여러 모델을 조합하여 단일 모델보다 더 좋은 성능을 내는 방법
- Bagging, boosting, stacking 방법을 활용

Model Selection

주요 고려 사항

- 데이터 크기, Feature 수, 예측 문제의 복잡성, 실행 시간, 해석 가능성, 그리고 마지막으로 하드웨어 제약 등을 고려해야 한다.
- Model selection은 대부분 experiment 기반 접근과 통계적인 방법론을 혼합하여 수행되며, 최종 목표는 실제 세계 데이터에 대한 예측력을 최대화하는 것

3. MLOps에서의 Model Selection

MLOps에서의 Model Selection

MLOps 관점

- MLOps 관점에서 model selection은 단순히 가장 높은 정확도를 가진 모델을 선택하는 것 이상의 의미를 가짐
- 모델의 성능뿐만 아니라, 배포 가능성, 유지 관리의 용이성, 확장성 및 비즈니스 요구 사항 충족 여부를 포함한 다양한 측면이 고려되어야 함
- 이런 고려사항이 포함된 기술 => AutoML (물론, 전부를 포함하지 못하나 일반적인 model selection 보다 더 좋은 접근법)